

2026 하계연수

미래 교육을 위한 AI 파트너: 다양한 거대언어모델(LLM)의 활용

동양미래대학교 인공지능소프트웨어학과

강환수 교수



Lecture 2: 인공지능망과 다양한 LLM

1. 인공지능과 인공지능망
2. OpenAI와 GPT 개요
3. 다양한 거대언어모델(LLM)

Section 1. 인공지능과 인공지능망



인공

인공호수, 이화원 내부의 곤명호

• 인공(人工)의 사전적 의미

- 인공이란 자연과 상반되게 우리 인간이 직접 만든 것을 의미
- '사람의 힘으로 자연에 대하여 가공하거나 작용을 하는 일'



인공호수

- 중국 명~청 시대의 별궁
- 북경 시내에서 서북쪽으로 약 19km 떨어진 이화원(頤和園)



인공섬

- 두바이 인공섬

이화원(頤和園)



중국 명~청 시대의 별궁으로 조성된
아름다운 인공호수

위치



북경 시내에서 서북쪽으로
약 19km 떨어진 위치

두바이 인공섬



두바이의 대표적인 인공섬
(팜 주메이라, 더 월드 등)

인공지능

- 인공지능

- 자연의 생물이 가지는 고유한 지능이 아닌,
'인위적으로 또는 그럴듯하게 만들어진 지능'



인공지능과 머신러닝, 딥러닝

- 인공지능이 가장 큰 범주
 - 인간의 지능을 “컴퓨터”로 구현
- 머신러닝
 - 데이터를 기반으로 기계 스스로 학습하는 인공지능의 한 분야
- 심층신경망인 딥러닝(deep learning)
 - 머신러닝의 여러 분야 중에서
 - 2010년 이후 현재의 인공지능 붐을 주도하고 있는 기술
 - 퍼셉트론으로 구성된 인공신경망
 - 여러 단계의 심층 학습을 통하여 스스로 학습하는 기술
 - 현재의 ChatGPT 등의 생성형 AI 분야
 - 거대언어 모델 LLM(Large Language Model)





그림 6.23 ▶ 인공지능과 머신러닝, 딥러닝의 이해

인공지능의 성공 원동력

인터넷, 모바일, 정보기술 발전

• 성공의 3 요소



하드웨어




엔비디아

AI 수퍼칩 GB200 한눈에 보기

최고 성능의 AI 컴퓨팅을 위한 엔비디아의 차세대 수퍼칩


1. GPU B200 (Blackwell GPU 단품 1개)



B200 GPU

- 약 3만 5,000달러 ~ 4만 달러
(약 4,600만 ~ 5,300만 원)

2. GB200 수퍼칩 (Grace CPU + B200 GPU 2개 결합)




Grace CPU

B200 GPU × 2

- 약 6만 달러 ~ 7만 달러
(약 8,000만 ~ 9,400만 원)

Grace CPU 1개 + B200 GPU 2개 결합

GB200 수퍼칩 내부 구조




고속 인터커넥트 NVLink-C2C로
CPU와 GPU가 하나처럼 동작하여
AI 성능을 극대화

엔비디아 AI 수퍼칩 GB200

주요 D램 제품

- HBM (고대역폭메모리)
- DDR (더블데이터레이트)
- LPDDR (저전력 더블데이터레이트)
- GDDR (그래픽 더블데이터레이트)



젠슨 황 엔비디아 CEO

블랙웰 GPU
(그래픽처리장치)

메모리: 5세대 HBM3E

GB200

그레이스 CPU
(중앙처리장치)

메모리: LPDDR5X

가격 비교 요약

제품	구성	가격 (달러)	가격 (원화)
B200 GPU (단품)	Blackwell GPU 1개	약 3만 5,000 ~ 4만	약 4,600만 ~ 5,300만
GB200 수퍼칩	Grace CPU 1개 + B200 GPU 2개	약 6만 ~ 7만	약 8,000만 ~ 9,400만

핵심 포인트



압도적 성능
Blackwell 아키텍처 기반
최고 성능 AI 컴퓨팅



CPU + GPU 통합
NVLink-C2C로
초고속 연결



AI 최적화 설계
대규모 모델 학습/추론에
최적화




프리미엄 가치
최고 성능에 걸맞은
프리미엄 가격

최신 플래그십 AI 슈퍼칩, NVIDIA GB200 NVL72

대규모 언어 모델 추론 시 엄청난 속도를 자랑하며, 실시간 AI 서비스의 성능을 극적으로 향상

- AI 슈퍼컴퓨터의 새로운 표준을 제시

- 조 단위 매개변수를 가진 초거대 AI 모델을 현실에서 구현할 수 있도록 지원
 - 36개(36 * (GPU B200 2개 + Grace CPU 1개)의 Grace Blackwell 슈퍼칩으로 구성
 - 72개의 GPU와 36개의 CPU, 고속 스위치 등이 거대한 하나의 “랙(Rack) 스케일 슈퍼컴퓨터”



알고리즘




뉴런(neuron)

- 신경계를 구성하는 신경세포 뉴런

- 신경계에서 전기적 및 화학적 신호를 통해 정보를 처리하고 전송하는 역할을 담당


- 신경계를 이루는 가장 기본적인 단위

- 자극을 전달하고 이에 대한 반응을 유도
- 우리가 뾰족한 물체에 찔리거나 뜨거운 물이 살갗에 닿았을 때 몸을 피하는 것
 - 신경세포가 외부 자극을 뇌에 전달하고,
자극을 피하라는 뇌의 명령을 다시 기관에 전달하기 때문



인간 대뇌피질의 뉴런

- 인간의 뇌에는 모두 860 ~ 1000억 개의 뉴런
 - 코끼리 뇌의 뉴런 수는 무려 2510억 개
 - 사람보다 거의 3배 가량 많음
- 사람이 더 뛰어난 지능을 갖는 이유
 - 대뇌피질의 역할
 - 언어, 의식, 기억, 집중 등 고차원적인 사고 활동의 증추적 역할
 - 인간이 코끼리보다 대뇌피질에 뉴런 수가 더 많기 때문
 - 사람 뇌의 대뇌피질에만 약 160억개의 뉴런이 존재하는 것으로 추산
 - 생물의 대뇌피질 중에 가장 많은 뉴런 수




인공 뉴런: 퍼셉트론


일반적인 신경세포(뉴런)의 구조

Perceptron

• 딥러닝, LLM의 근간



생물학적 뉴런을 단순화한 모델 = 퍼셉트론(Perceptron)



퍼셉트론
한 줄 요약



수식으로 표현하면

$$s = w_1x_1 + w_2x_2 + \dots + w_nx_n - b$$

$$y = f(s)$$


힌튼의 딥러닝: 층이 깊어도 학습이 가능하도록

최신 거대언어모델 LLM의 패러미터는 1조개를 넘음

- **인공인경망의 학습**

- 최적의 결과가 나올 수 있도록 패러미터를 학습
 - **패러미터를 결정**



패러미터



LLM의 발전

2017년 이후 인공지능 모델 발전

트랜스포머 이후 AI는 계속 진화하여 더 똑똑하고, 더 넓게 이해하고, 스스로 행동하는 시대로 발전했습니다.



PaLM (Google, 2022)

- 5,400억 개 파라미터의 초거대 언어모델
- 뛰어난 추론 · 다국어 · 코드 생성 성능
- 이후 PaLM 2 → Gemini로 발전

대규모 언어모델(LLM) 대표 모델



Section 2. OpenAI와 GPT 개요



OpenAI

2015년 일론 머스크(Elon Musk), 샘 올트먼(Sam Altman), 그렉 브록만(Greg Brockman), 일리아 수츠케버(Ilya Sutskever) 등을 포함한 여러 실리콘밸리 기업가와 연구자들에 의해 설립

- **목표**
 - 인공지능 연구 및 개발 기업으로, 안전하고 유용한 AI를 개발
 - AI가 인류에 미치는 영향을 신중하게 고려하며,
 - 인류 전체에 혜택을 줄 수 있는 방향으로 발전
 - 공개된 연구 및 오픈소스 AI 개발을 중심으로 활동
 - 비영리 법인으로 시작
- **2019 이후 제한적 영리 모델(OpenAI LP) 전환**
 - 투자자들에게 일정 한도 내에서 수익을 보장하면서도 AI의 공익적 사용을 유지하려는 시도
 - Limited Partnership(유한 합자회사)
 - 일론 머스크는 2018년에 회사와 결별
- **빠르면 2026년 4분기 상장 목표**
 - 비공개 IPO 신청서 제출
 - 2026년 5월 22일 미국 증권거래위원회(SEC)에 비공개로 기업공개(IPO) 등록 신청서(S-1) 제출
 - 2026년 한 해에만 약 140억 달러(약 21조 원)의 영업손실이 예상

마이크로소프트와의 협력

openAI의 49% 지분이 MS



Microsoft, OpenAI와 협력 및 AI 인프라 확대



차세대 AI 및 AGI 연구를 지원하기 위한 전략적 투자와 초대형 데이터센터 구축

1 Microsoft × OpenAI 전략적 협력

2019년



10억 달러 투자
OpenAI에 10억 달러 투자로
전략적 협력 시작



2023년



약 100억 달러 추가 투자
약 100억 달러 규모의
추가 투자 발표



협력의 성과



OpenAI 모델을
Microsoft Azure에서 학습·서비스



Microsoft 365, Bing 등
다양한 제품에 AI 기술 통합



Microsoft Copilot을 통해
업무 생산성 혁신

Microsoft Copilot

AI로 더 스마트한 일상과 업무



차세대 AI 및 AGI 연구를 지원하기 위한 초대형 AI 데이터센터 구축

AI 모델 학습과 추론을 위한 세계 최고 수준의 인프라 확장



2 미국 위스콘신 (Mount Pleasant)



70억 달러 이상 투자 계획
(약 10조 원 이상)



세계 최대 규모
AI 데이터센터 캠퍼스 구축




Frontier AI 모델 학습을 위한
초대형 GPU 인프라 운영 예정



위스콘신주 Mount Pleasant 지역에
대규모 AI 데이터센터 캠퍼스 구축 중

3 미국 텍사스 카스트로빌 (Castroville)



'SAT 82' AI 데이터센터
캠퍼스 (예정)



2026년 8월 13일
착공 예정



Azure AI 및 차세대 AI 서비스
인프라 확장 프로젝트



텍사스주 카스트로빌(Castroville) 지역에
신규 AI 데이터센터 캠퍼스 구축 예정



Microsoft의 비전

AI 혁신을 위한 투자와 인프라 확장을 통해 모든 사람이 AI의 혜택을 누리는 미래를 만들어갑니다.



구글의 Transformer 알고리즘

Transformer 알고리즘은 2017년 Google Brain 팀이 발표한 논문 "Attention Is All You Need"에서 처음 소개

- "Attention is All You Need" 논문

- 기존의 순환 신경망(RNN) 및 컨볼루션 신경망(CNN) 기반 시퀀스 변환 모델의 한계를 극복
 - 어텐션 메커니즘만을 사용
 - 더 나은 성능과 병렬 처리가 가능한 새로운 아키텍처인 Transformer를 제안

- 2017년 수학적 기법을 응용해 개발

- 서로 떨어져 있는 데이터 요소의 의미관계를 파악하는 트랜스포머 모델을 공개
- 17년 구글 트랜스포머 발표 후 수많은 인공지능 모델이 응용되어 발전
- GPT, BERT, LLaMA 등 대부분의 LLM의 근간

OpenAI의 GPT

GPT(Generative Pre-trained Transformer)는 OpenAI에서 개발한 자연어 처리(NLP) 모델

- 대량의 텍스트 데이터를 학습한 후 이를 기반으로
 - 다양한 언어 작업을 수행하는 인공지능 모델
 - 텍스트 생성, 번역, 요약 등
- 주요 특징
 - 트랜스포머(Transformer) 아키텍처를 기반
 - 사전 학습(Pre-training)과 미세 조정(Fine-tuning) 과정으로 이루어짐
 - 최근 GPT-5.6까지 발전
 - GPT-5.6 Sol
 - GPT-5.6 Terra
 - GPT-5.6 Luna
 - 멀티모달 기능
 - 텍스트 뿐만 아니라 이미지 입력까지 처리 가능
- 기능
 - 대량의 데이터와 맥락을 처리할 수 있는 기술
 - 문장 속의 단어와 같은 순차적인 데이터 내의 관계를 추적해 맥락과 의미를 학습

토큰과 컨텍스트 이해

1 Token과 Context의 이해

LLM은 문장을 '토큰(Token)' 단위로 이해하고, Context를 바탕으로 답변을 생성한다.



1 Token(Token)이란?

LLM이 텍스트를 처리하는 최소 단위로, 단어, 단어의 일부, 기호 등이 하나 이상의 토큰으로 분리된다.

예시

한국어 예시 안녕하세요. → 안녕 하세 요 .
= 4개의 토큰

영어 예시 Artificial Intelligence → Artificial Intelligence
= 2개의 토큰

💡 토큰은 글자 수와 다르며, 모델마다 토큰화(Tokenization) 방식이 다를 수 있다.

2 Context(Context)란?

LLM이 답변을 생성하기 위해 현재 참고하는 모든 정보를 의미한다.



🎯 Context는 위의 모든 정보를 포함하며, 이들을 바탕으로 LLM이 답변을 생성한다.

핵심 정리



Token

LLM이 텍스트를 처리하는 최소 단위(토큰)



Context

답변 생성을 위해 현재 참고하는 모든 정보



LLM은 Token을 읽고, Context를 바탕으로 답변을 생성한다.

한눈에 보는 흐름



텍스트 입력
(문장)
“오늘 날씨 어때?”

Token 단위로 분리

오늘 날씨 어때 ? ...

Context를 기반으로 이해



이전 대화, 문서, 질문 등 모든 정보를 종합하여 의미를 파악한다.

답변 생성



“오늘은 맑고, 기온은 25도입니다.”

컨텍스트 토큰


2 Context Tokens란?

현재 LLM이 참고하고 있는 전체 토큰 수를 의미한다.



Context Tokens = 현재 Context를 구성하는 전체 토큰 수
즉, 답변을 생성하기 위해 모델이 참고하는 모든 정보의 토큰 합계이다.


더 많은 정보가 포함될수록
Context Tokens가 증가한다!



특징

- ✓ 대화를 계속하면 증가한다.
- ✓ 긴 문서나 파일을 업로드하면 증가한다.
- ✓ 모델이 답변을 생성할수록 증가한다.


Context Tokens는 무엇으로 구성될까?



구성 요소별 예시 (토큰 수 예시)

구성 요소	토큰 수 (예시)
시스템 프롬프트	2,000
이전 대화	18,000
첨부 PDF (논문)	55,000
사용자 질문	3,000
생성 중인 답변	2,000
합계 (Context Tokens)	80,000

한눈에 보는 예시



참고 토큰(Token)은 글자 수와 다르다!



일반적으로 1토큰 ≈ 0.75개의 영어 단어 정도로 계산된다. (모델과 언어에 따라 차이 있음)

길이 감지 예시 (대학)

100 토큰
약 70~80개
영어 단어

1,000 토큰
약 700~800개
영어 단어

10,000 토큰
약 7,000~8,000개
영어 단어

100,000 토큰
약 300~500페이지
분량의 문서(영어)



중요 공식!

Context Tokens ≤ Context Window
(다음 페이지에서 계속)

컨텍스트 윈도우

3 Context Window란?

LLM이 한 번에 처리할 수 있는 최대 토큰 수



물통의 크기가
Context Window라면,
현재 담긴 물의 양이
Context Tokens예요!



Context Window = 모델이 동시에 처리할 수 있는 최대 토큰 수
이 한계를 넘으면 일부 정보가 제외되거나, 답변 길이가 제한된다.

Context Tokens가 누적되는 과정 (예시 흐름)



Σ 합계 (Context Tokens) = 80,000 토큰

※ 예시는 상황에 따라 달라질 수 있습니다.



중요 포인트

모델은 위의 모든 정보를 함께 참고하여 답변을 생성한다.
따라서 Context Tokens가 많을수록 더 많은 정보를 한 번에 이해할 수 있다!

Context Window와의 관계 (비유: 물통)

✓ 정상 범위

Context Window = 128,000 토큰



80,000 < 128,000

→ 모든 정보를 유지하고
정상적으로 답변 생성

⚠ 초과 상황

Context Window = 128,000 토큰



145,000 > 128,000

→ 일부 오래된 대화/문서가 제거되거나
답변 길이가 제한될 수 있음

핵심 비교

Context Tokens
(현재 사용량)



현재 참고하고 있는
전체 토큰 수

- ✓ 대화가 길어지면 증가
- ✓ 문서를 업로드하면 증가
- ✓ 답변을 생성할수록 증가
- ✓ 항상 변함

Context Window
(최대 용량)



모델이 한 번에 처리할 수
있는 최대 토큰 수

VS

- ✓ 모델마다 고정되어 있음
- ✓ 변하지 않음
- 예) GPT-4o: 128K
- 예) GPT-4 Turbo: 128K
- 예) Claude 3.5: 200K

초과 시 LLM의 처리 방식



오래된 대화 일부 제거 (Truncation)
가장 앞부분의 정보를 먼저 제외



관련성이 낮은 정보 축소
중요도가 낮은 내용을 요약하거나 제거



답변 길이 제한
생성 가능한 최대 토큰 수가 줄어듦

한눈에 보는 공식



Context Tokens ≤ Context Window


현재 사용량 ≤ 최대 용량

토큰이란?



텍스트를 모델이 처리하는 최소 단위(토큰)
한글, 영어, 숫자, 기호 등이 하나 이상의 토큰으로
분해되어 처리된다.

토큰 크기 감(대략적인 기준)



참고

- ✓ 모델마다 Context Window 크기가 다르다.
- ✓ 긴 컨텍스트를 효과적으로 활용하려면, 중요한 정보를 선별하여 넣는 것이 핵심이다!
- ✓ 예) GPT-4o: 128K | GPT-4 Turbo: 128K | Claude 3.5: 200K | Gemini 1.5 Pro: 1M

주요 GPT 버전

GPT 주요 버전의 발전 (사용자 관점)

사용자 경험의 변화로 보는 GPT의 진화

버전	GPT-1	GPT-2	GPT-3	GPT-4	GPT-5	GPT-5.5
출시년도	2018	2019	2020	2023	2025	2026
사용자가 체감한 가장 큰 변화	사람처럼 문장을 이어서 생성할 수 있는 가능성을 보여준 초기 AI	더 자연스럽고 긴 글을 작성하며 간단한 질문에도 답할 수 있게 됨	다양한 질문에 높은 수준으로 답하고 번역·요약·코드 작성까지 가능해짐	이미지까지 이해하고, 더욱 정확하고 전문적인 답변을 제공함	단순 답변을 넘어 복잡한 문제를 단계적으로 해결하고 도구를 활용하는 AI 비서로 발전	긴 프로젝트를 계획·수행하고 여러 작업을 스스로 연결하는 AI 에이전트로 가까워짐
						
	문장 생성	장문 생성	범용 AI	멀티모달 AI	AI 비서	AI 에이전트
	- 짧은 문장 이어쓰기 - 기본적인 텍스트 생성	- 블로그 글 작성 - 자연스러운 장문 생성	- 질문 응답 - 번역, 요약 - 코드 작성	- 이미지 이해 및 설명 - 표, 그래프 해석 - 더 정확한 전문 답변	- 단계적 문제 해결 - 도구(검색, 코드 실행 등) 활용 - 일정 관리, 문서 정리 지원	- 프로젝트 계획 및 실행 - 여러 작업 자동 연결 - 자율적 의사결정 지원



💡 핵심 한 줄 요약 문장 생성의 시작 > 긴 글 작성 > 무엇이든 물어볼 수 있는 범용 AI > 글과 이미지를 함께 이해 > 복잡한 업무를 도와주는 AI 비서 > 스스로 계획하고 실행하는 AI 에이전트

Section 3. 다양한 거대언어모델(LLM)



다양한 거대언어모델(LLM) 서비스

• 자체 거대언어모델 서비스


- chatGPT
- claude
- Gemini
- grok(x.ai)
- LLAMa
- felo.ai
- manus.im (에이전트 중심)
- copilot.microsoft.com
- goover.ai
- deepseek.ai
- qwenlm.ai



ChatGPT – Open AI



Copilot – Microsoft



Claude - Anthropic



CLOVA X - Naver



Gemini - Google



• 거대언어모델 검색, 에이전트 서비스(작성 + 검색): Answer Engine

- perplexity.ai
- wrtn.ai
- genspark.ai (다중 거대언어모델 제공)
- a.sktelecom.com (다중 거대언어모델 제공)
- liner.com (다중 거대언어모델 제공)

Gemini.google.com

Google DeepMind가 개발한 멀티모달 생성형 AI 플랫폼

- 2.0 출시 이후로 다시 관심

- 성능 향상
- 무료로 어느 정도 사용 가능

- 특징

- 텍스트와 이미지를 동시에 처리할 수 있는 강력한 기능을 제공
- 자연어 처리와 컴퓨터 비전 기술을 통합하여 사용자에게 보다 직관적이고 효율적인 경험을 제공
- 검색, 번역, 콘텐츠 생성, 데이터 분석 등 다양한 애플리케이션에 활용
- Google의 검색 및 클라우드 생태계와 밀접히 연결
- 특히, 개발자와 비즈니스 사용자를 위한 생산성 도구로 각광
- 한글 글쓰기에 적합
- 인포그래픽
 - 배경화면이 화려

Claude.ai

Anthropic에서 개발한 생성형 AI

- Anthropic

- OpenAI에서 연구를 진행하던 연구자들이 2021년 설립
- AI 기술의 발전이 잠재적으로 가져올 위험성을 인식
 - 이러한 위험을 완화하고 AI가 인간에게 신뢰할 수 있는 도구로 자리 잡도록 하는 것을 목표
 - AI 기술이 보다 윤리적이고 신뢰할 수 있는 방향으로 나아가고자 하는 Anthropic의 철학을 반영하는 모델

- 특징

- 사용자의 요청에 대해 안전하고 책임 있는 방식으로 응답하도록 설계
- 대화 생성, 문서 작성, 요약, 코딩 등의 작업에서 뛰어난 성능
- 인간의 지침을 더 잘 이해하도록 훈련된 AI
- 윤리적 AI 원칙에 따라 설계
- 사용자와의 상호작용에서 부적절한 콘텐츠 생성을 방지하는 데 중점
- 기업과 개인 사용자 모두를 위한 API와 사용자 친화적인 인터페이스를 제공

- 코딩에 좋은 결과

주요 LLM 서비스 비교

대표 LLM 서비스와 최신 모델 (2026년 기준)

사용자 관점에서 본 특징과 가장 잘하는 분야

서비스	ChatGPT	Gemini	Claude	Microsoft Copilot	Perplexity	Grok
개발사	 OpenAI	 Google	 Anthropic	 Microsoft	 Perplexity AI	 xAI
최신 대표 모델 (2026년 기준)	GPT-5.5	Gemini 2.5 Pro	Claude Opus 4.8	GPT-5.5 기반 Copilot	여러 최신 모델 선택 가능 (GPT-5.5 / Claude / Gemini 등)	Grok 4.3
사용자 관점 특징	가장 균형 잡힌 AI. 글쓰기, 코딩, 데이터 분석, 이미지 이해, 복잡한 업무 수행까지 전반적으로 우수	Google 검색, Gmail, Docs, Drive, Android와 자연스럽게 연동되며 긴 컨텍스트 처리에 강함	긴 문서 분석, 논문 요약, 프로그래밍, 복잡한 추론에서 높은 성능 제공	Word, Excel, PowerPoint, Outlook 등 Microsoft 365와 긴밀하게 통합되어 업무 생산성을 높여줌	최신 웹 검색과 출처 제시에 강하며, 여러 최신 모델을 선택하여 사용할 수 있음	X(구 Twitter)와 연동되어 실시간 뉴스, SNS 트렌드, 시사 정보 분석에 강점
가장 잘하는 분야	 범용 AI 비서	 Google 업무 (검색·문서·메일 등)	 문서·논문 분석 코딩·추론	 Office 업무 (문서 작성·분석)	 검색·리서치 (출처 확인)	 실시간 정보·SNS 분석



서비스와 모델의 차이

- 서비스(Service) : 우리가 사용하는 앱이나 웹 서비스 (예: ChatGPT, Gemini, Claude 등)
- 모델(Model/LLM) : 서비스 안에서 실제로 대화를 이해하고 답변을 생성하는 AI 모델 (예: GPT-5.5, Gemini 2.5 Pro 등)

LLM 모델 성능 비교

- <https://llm-stats.com/>

RANK	MODEL	LLM STATS	REASONING	CODING	AGENT	CODE ARENA	PARAMS	CONTEXT	SPEED	PRICING \$/M	LICENSE
1	GPT-5.6 Sol OpenAI	58.0	58.1	50.1	44.6	—	—	1.1M	221 c/s	\$7.78	
2	Claude Opus 5 Anthropic	58.0	57.7	42.7	43.9	—	—	1.0M	126 c/s	\$7.22	
3	Claude Fable 5 Anthropic	57.5	55.3	48.4	44.3	—	—	1.0M	90 c/s	\$14.44	
4	Claude Mythos Preview Anthropic	56.1	56.6	46.6	38.2	—	—	—	—	—	
5	Kimi K3 Moonshot AI	55.7	54.9	44.9	42.2	—	2.8T	1.0M	67 c/s	\$4.33	
6	GPT-5.6 Terra OpenAI	53.3	52.1	46.0	40.7	—	—	1.1M	317 c/s	\$3.89	
7	Claude Opus 4.8 Anthropic	52.6	52.1	43.9	37.9	—	—	1.0M	87 c/s	\$7.22	
8	Muse Spark 1.1 Meta	52.1	52.3	38.3	37.3	—	—	1.0M	241 c/s	\$1.58	
9	Claude Sonnet 5 Anthropic	50.9	50.3	40.4	35.4	—	—	1.0M	141 c/s	\$4.33	
10	Grok 4.5 xAI	49.5	48.2	40.5	35.4	—	—	500K	184 c/s	\$2.44	
11	GPT-5.5 OpenAI	49.1	48.3	41.1	34.0	—	—	1.1M	176 c/s	\$7.78	
12	Seed 2.1 Pro ByteDance	47.3	48.2	36.3	32.4	—	—	—	—	—	

주가 총액으로 보는 AI



글로벌 AI·빅테크·반도체 기업 가치 비교 (2026년 5월 초 기준)

2026.5 기준

구분	기업명	기업 가치 (달러)	기업 가치 (원화 약)
빅테크	엔비디아 (NVDA)	약 4.34조 달러	약 6,510조 원
빅테크	알파벳 (GOOGL)	약 3.70조 달러	약 5,550조 원
빅테크	애플 (AAPL)	약 3.66조 달러	약 5,490조 원
빅테크	마이크로소프트 (MSFT)	약 2.89조 달러	약 4,335조 원
AI 업체	OpenAI	약 0.85조 달러	약 1,275조 원
AI 업체	Anthropic (Claude)	약 0.35조 달러	약 525조 원
AI 업체	Manus (메타 26/12 인수, 이후 취소)	약 0.002조(20억) 달러	약 3조 원
반도체	TSMC	약 1.20조 달러	약 1,800조 원
반도체	삼성전자	약 0.55조 달러	약 820조 원
반도체	SK하이닉스	약 0.20조 달러	약 300조 원

1990년 · 2010년 · 2026년 미국 시가총액 Top10 비교

36년간 미국 경제의 중심은 자원 → 플랫폼 → AI로 이동

1990년 Top10



석유·제조·소비재 중심
산업경제 시대

1	ExxonMobil	Exxon Mobil
2	IBM	IBM
3	Walmart	Walmart
4	Bristol-Myers Squibb	Bristol-Myers Squibb
5	MERCK	Merck
6	Coca-Cola	Coca-Cola
7	GE	General Electric
8	P&G	Procter & Gamble
9	Johnson & Johnson	Johnson & Johnson
10	verizon	Verizon

2010년 Top10



모바일·플랫폼 부상
전환기

1	ExxonMobil	Exxon Mobil
2	Apple	Apple
3	Microsoft	Microsoft
4	BERKSHIRE HATHAWAY	Berkshire Hathaway
5	Walmart	Walmart
6	Google	Alphabet
7	Chevron	Chevron
8	P&G	Procter & Gamble
9	IBM	IBM
10	Johnson & Johnson	Johnson & Johnson

2026년 Top10



AI·반도체·클라우드 중심
AI 시대

1	NVIDIA	
2	Apple	Apple
3	Alphabet	Alphabet
4	Microsoft	Microsoft
5	Amazon	Amazon
6	BROADCOM	Broadcom
7	Meta	Meta
8	Tesla	Tesla
9	Eli Lilly	Eli Lilly
10	Micron Technology	Micron Technology

주요 추세

1. 산업 중심의 변화



2. 기업의 가치 원천 변화



3. 핵심 기업의 변화



4. 큰 흐름



핵심 인사이트

미국 경제의 중심은 '자원 → 플랫폼 → AI'로 진화하고 있으며,
앞으로 기업 경쟁력은 AI와 데이터 인프라 확보에 달려 있다.

